



计算机科学与探索

Journal of Frontiers of Computer Science and Technology

ISSN 1673-9418,CN 11-5602/TP

《计算机科学与探索》网络首发论文

题目: LLM 知识增强与特征门控融合的虚假信息检测
作者: 翁克瑞, 张薇, 於世为, 黄瑞云
网络首发日期: 2026-04-03
引用格式: 翁克瑞, 张薇, 於世为, 黄瑞云. LLM 知识增强与特征门控融合的虚假信息检测[J/OL]. 计算机科学与探索.
<https://link.cnki.net/urlid/11.5602.TP.20260402.1756.002>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

LLM 知识增强与特征门控融合的虚假信息检测

翁克瑞, 张薇, 於世为⁺, 黄瑞云

中国地质大学(武汉) 经济管理学院, 武汉 430078

⁺ 通信作者 E-mail: yusw@cug.edu.cn

摘要: 针对社交媒体虚假信息在语义表达隐含、内容结构复杂及传播行为多样等情境下的识别需求, 对融合大语言模型推理能力与多源特征表示的统一检测框架进行了研究。研究旨在通过引入推理式知识与多维特征协同建模, 提高虚假信息检测的准确性, 并增强模型决策过程的透明性。构建了一种大语言模型知识增强的双门控融合框架(LLM-EDGF), 通过结构化提示流程引导大语言模型生成与文本事实一致性、逻辑连贯性相关的推理式知识特征, 并与 BERT 提取的深层语义表示进行联合建模; 同时引入用户画像特征与传播行为特征, 对信息发布主体属性及其扩散特征进行刻画。在特征融合阶段, 分别在“知识—语义”和“内容—社交”两个层面设计双阶段门控机制, 实现多源特征的动态加权融合与噪声信息抑制, 最终通过轻量化分类器完成虚假信息检测任务。在多个公开数据集及自建微博数据集上的实验结果表明, 该框架在整体检测性能上优于对比模型, 并在事实部分编造、叙事逻辑不连贯等复杂虚假信息场景中表现出更稳定的识别能力。此外, 推理式知识特征的引入为模型决策过程提供了可追溯的信息依据, 验证了该方法在虚假信息检测任务中的适用性。

关键词: 大语言模型; 知识增强; 虚假信息识别; 门控融合; 社交特征

文献标志码: A **中图分类号:** TP391

LLM Knowledge Enhancement and Feature Gated Fusion for Fake News Detection

WENG Kerui, ZHANG Wei, YU Shiwei⁺, HUANG Ruiyun

School of Economics and Management, China University of Geosciences (Wuhan), Wuhan 430078, China

Abstract: In response to the challenges of detecting social media misinformation under conditions of implicit semantic expression, complex content structures, and diverse propagation behaviors, this study investigates a unified detection framework that integrates the reasoning capabilities of large language models with multi-source feature representations. The objective is to improve misinformation detection accuracy through the joint modeling of reasoning-based knowledge and multi-dimensional features, while enhancing the transparency of the model's decision process. A large language model-enhanced dual-gated fusion framework (LLM-EDGF) is developed, in which a structured prompting procedure is employed to guide the large language model to generate reasoning-based knowledge features related to factual consistency and logical coherence of the text, which are then jointly modeled with deep semantic representations extracted by BERT. In addition, user profile features and propagation behavior features are incorporated to characterize the attributes of information publishers and diffusion patterns. At the feature fusion stage, a two-stage gating mechanism is designed at both the

教育部人文社会科学研究规划基金项目(24YJA630101); 国家自然科学基金项目(72474201)。

This work was supported by the Ministry of Education Humanities and Social Science Research Planning Fund Project (24YJA630101) and the National Natural Science Foundation of China (72474201).

“knowledge-semantic” and “content-social” levels to achieve dynamic weighting of multi-source features and suppression of noisy information, and a lightweight classifier is finally applied for misinformation detection. Experimental results on multiple public datasets and a self-constructed Weibo dataset demonstrate that the proposed framework outperforms comparative models in overall detection performance and exhibits more stable recognition capability in complex misinformation scenarios such as partial fabrication of facts and incoherent narrative structures. Furthermore, the introduced reasoning-based knowledge features provide traceable information for the model’s decision process, supporting the applicability of the proposed approach to social media misinformation detection tasks.

Key words: Large Language Model; knowledge enhancement; misinformation identification; gated fusion; social featur

随着社交媒体成为主要信息传播渠道, 信息传播与获取方式发生了极大改变, 但也带来了“信息污染”的严峻挑战, 虚假信息的传播愈发频繁且难以遏制^[1]。虚假信息的形式和伪装手段不断演化, 由早期以情绪渲染和语言偏差为主的低质量内容, 逐渐转向结构完整、叙事连贯、包含部分真实信息但伴随误导性叙述的高仿真伪造。这类内容往往在句间逻辑、跨段因果链条以及常识一致性方面构造精巧, 使其在表层语义上与真实信息高度相似, 导致传统基于语义相似性的检测方法难以准确识别。即便是 BERT (Bidirectional Encoder Representations from Transformers) 等预训练模型, 在处理跨句逻辑冲突、事实矛盾或因果跳跃等深层伪造模式时仍缺乏推理能力, 无法从文本内部对内容的真实性进行系统化的判断。如何弥补语义模型在事实推理与逻辑一致性识别上的能力缺口, 成为当前虚假信息检测的重要挑战。

另一方面, 研究表明虚假信息往往伴随独特的社交行为与发布者特征, 例如低信誉用户^[2]、异常传播链路^[3]或高频情绪化转发行为。这些用户与传播特征在理解信息可信度方面具有不可替代的价值。然而, 现有方法普遍采用早期拼接或晚期加权的方式将社交特征与文本特征简单组合, 这种静态融合方式存在明显局限: 一是不同特征来源在尺度、噪声水平和语义结构上差异显著, 直接拼接容易造成维度冲突和噪声扩散; 二是固定加权方式无法适应内容可信度与发布者可信度可能相互矛盾的复杂社交场景, 导致融合结果不稳定、可解释性不足。要充分发挥社交维度的判别价值, 需要一种具备动态调节能力、可控性与鲁棒性的跨域融合机制。

近年来, 大语言模型 (Large Language Model, LLM) 在事实校验、逻辑推理与文本一致性分析中展现出显著优势, 为应对高仿真虚假信息提供了新的思路, 能够在跨句推理、常识判断与逻辑链路分析方面弥补传统语义模型的不足^[4]。然而, 直接将 LLM 用于分类任务仍面临多重困难: 其生成过程带有一定不可控性, 易产生幻觉; 输出形式以自然语言为主, 不具备结构化特征的可训练性; 同时难以与用户属性、传播行为等结构化社交特征在统一框架中融合^[5]。因此, 如何在保留 LLM 推理能力的前提下, 控制其噪声与不稳定性, 并与语义表征及社交行为特征协调融合, 是待解决的关键问题。

基于上述挑战, 本文提出 LLM-EDGF (LLM-Enhanced Dual-Gated Fusion Framework), 构建一个融合知识推理、内容语义与社交行为的统一检测框架。首先, 我们将智谱 GLM-4.5-Flash 用作知识增强编码器, 通过结构化提示指导 LLM 输出可量化的事实一致性评分、逻辑一致性评分等推理特征, 以补足 BERT 在事实与逻辑推理维度的不足。随后, 引入内部融合门 (Internal Fusion Gate, IFG), 在“知识推理-语义内容”内部实施选择性整合, 以抑制 LLM 幻觉带来的噪声并实现深层推理与稳定语义的互补。最后, 为解决内容可信度与发布者可信度之间的跨域冲突, 我们设计跨域平衡门 (Domain Balance Gate, DBG), 在融合用户画像与传播行为时动态调节不同信息源的重要性, 使模型能够适应社交媒体环境中常见的身份伪装、异常传播与噪声干扰。通过双阶段门控机制, LLM-EDGF 实现了推理层、内容层与行为层的协同建模, 解决了传统融合方式的稳定性与可解释性瓶颈。

综上所述,本文的主要贡献如下:(1)提出一种 LLM × BERT 互补的知识增强机制,将 LLM 的推理能力以结构化特征形式注入深度模型,实现深层推理与细粒度语义的融合;(2)设计双阶段门控融合结构,通过 IFG 实现推理与语义的内部选择性融合,并通过 DBG 在内容与社交行为之间建立起动态适配关系,从而有效缓解多源特征冗余与耦合问题;(3)构建统一的“推理—内容—社交”跨域检测框架,在公开数据集和自建微博数据集上验证其优越性,特别是在复杂的社交场景下展现出显著的判别优势,体现出本研究在多源信息融合与知识增强的虚假信息检测方向的重要价值。

1 研究现状

近年来,社交媒体虚假信息检测已形成跨文本语义分析、用户行为建模、多源特征融合与大语言模型推理等多条技术路径。现有研究虽在各自方向取得了显著进展,但仍未形成能够系统整合语义内容、推理知识与社交行为的统一框架。

1.1 多源特征融合的虚假信息检测方法

针对社交媒体的虚假信息检测,研究者普遍认为仅依赖文本内容难以覆盖虚假信息的多样化表达与语境差异,因此大量工作引入多源信息进行联合建模,包括用户画像特征^[6]、互动行为特征^[7]等社交上下文信息。在融合策略上,早期研究普遍将这些特征视为独立变量,与文本内容进行静态拼接^[8]或线性组合^[9],尽管操作简便,但忽略了不同特征空间在尺度、噪声和语义层级上的结构差异,容易引发维度冲突^[10]或特征冗余。随后,研究者引入注意力机制、门控机制等动态融合结构,使模型能够根据不同信息源的可靠性自动调整权重。Qian 等^[11]提出了 DynCIM 方法,使用动态网络架构和门控机制调整模态权重,说明了门控机制在抑制冗余信息方面的作用;Du^[12]和 Kumar^[13]的门控注意力融合模型在情感分类中表现优异,说明了两种机制的结合优势。然而,现有融合方法主要适用于模态间协同,并未充分解决“语义内容—推理知识—社交行为”这类跨域特征之间本质异构的问题。尤其在虚假信息检测场景中,内容信息与社交信号在早期传播或争议事件中可能相互冲突,模型需要具备更

强的动态权衡与可解释性以避免过度依赖单一信息源。

1.2 LLM 在虚假信息检测中的应用

近年来,大语言模型在文本理解与推理方面展现出较强能力,为虚假信息检测提供了新的技术范式。一类方法直接将检测任务以 Zero-Shot^[14]或 Few-Shot^[15]的形式交给 LLM 完成判别或生成解释,例如 Zhou 等^[16]直接利用 LLM 对社交媒体上的错误信息进行纠正,SNIFFER 通过多模态 LLM 实现可解释的上下文错误信息检测^[17],这类方法的优势在于无需大量标注数据即可获得一定泛化能力;但同时也存在输出不稳定、可复现性不足以及对提示敏感等问题,并可能受到幻觉与事实性错误影响。另一类研究将 LLM 作为知识与推理能力提供者,通过检索增强生成(Retrieval-Augmented Generation, RAG)辅助检索外部证据^[18],再与判别模型结合以提升鲁棒性与可控性。

尽管 LLM 推理带来新的机遇,但仍面临非结构文本输出、幻觉与稳定性不足,以及与结构化特征的融合困难等问题。目前的研究多将 LLM 视作外部推理器或弱监督标签生成器,尚未形成与深度神经网络协同的高效融合机制。因此,如何实现 LLM 知识推理的可控注入与语义—行为特征的联合优化,仍是待深入研究的问题。

综上,多源特征融合方法在提升检测性能方面有效,但在“内容—社交冲突”与信息源不稳定场景下仍缺少可控的推理证据来支撑动态决策;而 LLM 相关方法要么直接判别易受幻觉与提示敏感性影响,要么缺少与多源融合机制的紧密耦合。为此,本文将 LLM 用于生成结构化推理特征以增强内容可信度建模,并提出双阶段门控融合机制在内容与社交特征之间进行动态权衡,从而在保证有效性的同时提升模型的可解释性与适用性。

2 实验模型

2.1 总体架构: LLM-EDGF (LLM-Enhanced Dual-Gated Fusion Framework)

图 1 展示了 LLM-EDGF 模型的整体架构,由三大核心模块构成:第一部分为内容表示模块,涵盖用于生成推理式知识向量的 LLM 推理单元以及用于获取深层语义特征的 BERT 编码器,两者协同构建包含语义与推理信息的内容增强表征。第二部分为双阶段门控

融合模块, 由内部融合门 IFG 与跨域平衡门 DBG 组成: 前者在语义特征与推理知识之间实现分域内的选择性整合, 后者在内容表征与用户属性、传播行为等社交侧特征之间建立跨域动态平衡机制, 以缓解多源信息

的冗余与耦合问题。第三部分为分类模块, 以融合后的统一向量为输入, 通过轻量化改进的多层感知机 (Multilayer Perceptron, MLP) 完成真假信息的概率预测。




图 1 LLM-EDGF 模型框架图

Fig.1 LLM-EDGF Model Framework Diagram

在整体流程中, 框架以文本内容、用户属性指标和传播行为数据为输入, 通过 LLM 和 BERT 的联合编码生成可信度增强的内容表示, 再经过双阶段门控结构引入并调节社交行为特征的影响, 最终形成适用于虚假信息检测的跨域综合表征, 为复杂社交场景下的判别任务提供更有效的技术支持。

2.2 LLM 知识增强编码器

LLM 在虚假信息检测任务中, 文本往往包含复杂的逻辑结构、隐含的事实关联以及跨句因果链条, 仅依赖传统语义模型难以充分捕捉内容内部的深层关系^[19]。为突破 BERT 等模型在事实推理与常识校验方面的能力上限, 本研究引入大语言模型作为知识增强编码器, 通过结构化推理与知识生成将抽象的语义关联转化为可学习、可量化的特征。该模块的核心目标不

是让 LLM 直接完成分类任务, 而是通过严格约束的 Prompt 引导其执行事实核验、逻辑一致性分析和常识判断^[20], 从而生成能够补充内容语义的知识表达。

LLM 会对输入文本构建多层推理链条, 首先从事实层面评估文本叙述与广泛接受的知识之间的契合度, 再从逻辑层面分析句子与句子之间的因果与条件关系是否存在跳跃、断裂或自相矛盾的情况。同时, 模型还会识别潜在的仿真式伪造模式, 例如基于部分真实事实进行延伸、在细节处制造不一致、或通过情绪化叙事隐藏逻辑缺口。为了确保其输出能够进入神经网络进行端到端训练, 本研究将 LLM 的自然语言推理结果转化为结构化指标, 包括事实一致性评分、逻辑连贯性评分等。这些量化特征不仅描述了文本的显性内容, 更反映出语义背后潜在的知识结构和逻辑关系, 从而弥补传统语义模型在推理维度上的不足。




图 2 大语言模型提示词设计

Fig.2 LLM Prompt Design

图 2 展示了 LLM 提示流程：先用角色设定将模型固定为中立的事实核查分析员；随后在约 300 词内输出结构化要素，包括可核验断言、来源可靠性、情绪用语与背景；最后按固定格式给出两项 0–1 数值评分：逻辑连贯性与事实一致性。该流程把自由文本推理压缩为可控、可量化的特征，为后续与 BERT 语义向量的门控融合提供稳定输入。（不同提示模板对输出稳定性的影响与幻觉风险控制见第 3.3 节）

2.3 BERT 语义编码器

BERT 通过双向 Transformer 结构，能够捕捉上下文中的复杂语义关系^[21]。这种深层语义建模能力对于虚假信息中隐含的逻辑矛盾、语义漂移等特征具有重要意义。BERT 的优势在于其对复杂语义和上下文依赖的建模能力，能够显著提升模型对文本内容的理解

力，尤其是在处理长文本或语义复杂的场景时表现出色^[22]，但无法捕捉深层逻辑与事实一致性，因此与 LLM 形成互补。

2.4 社交特征

在虚假信息检测任务中，仅依赖文本语义难以全面刻画信息的可信度。社交特征（如用户属性与传播行为）往往能够反映信息发布者的可信程度、社交关系结构及消息传播的异常模式。因此，本研究将用户与传播特征进行统一建模，构成社交特征向量 $\mathbf{U}$ ，并在之后的跨域融合中与内容特征（ $\mathbf{C}$ 、 $\mathbf{K}$ ）共同参与决策。

用户画像特征通过刻画信息发布者的社会身份、账号质量与历史活动模式，为内容真实性判断提供补充证据。本研究选取以下常见且具有区分能力的用户特征：

等级（level）：反映账号活跃程度；采用 Min–Max 归一化 将其映射至[0,1]。

认证状态（verified）：官方认证则记为 1，否则为 0。

粉丝数（followers）：数量级差异巨大，采用 $\log(1+x)$ 变换 + 标准化（Z-score），降低极端值影响。

关注数（followings）：同样采用 对数压缩 + 标准化处理。

发布微博数（posts）：使用 log-normalization，反映账号活跃度。

以上特征构成用户画像特征向量：

$$\mathbf{U}_{\text{user}} \in \mathbb{R}^{d_u} \quad (1)$$

其中， $\mathbf{U}_{\text{user}}$ 由等级、认证状态、粉丝数、关注数与发博数等特征按固定顺序拼接得到； d_u 表示用户画像特征维度。

传播行为能够反映消息被受众接受、质疑或批判的程度，也有助于识别典型的爆发式虚假信息。本研究选取以下传播特征：

评论数（comments）：采用 $\log(1+x)$ 消除长尾效应。

转发数（reposts）：同样使用 log-normalization。

点赞数（likes）（如数据可用）：采用对数压缩，

使其与其他传播特征尺度一致。

异常值处理：对所有传播特征采用分位数裁剪（如 0.5%–99.5%），避免极端热点事件造成统计偏移。

传播行为特征构成：

$$U_{\text{prop}} \in \mathbb{R}^{d_p} \quad (2)$$

其中， U_{prop} 表示传播行为、互动统计特征向量； d_p 为传播特征维度。

将用户画像特征与传播行为特征拼接为最终的社交特征：

$$U = [U_{\text{user}}; U_{\text{prop}}] \in \mathbb{R}^{d_u+d_p} \quad (3)$$

由于社交特征与内容特征（ C 、 K ）在统计分布和特征空间上存在差异，为保证在后续门控融合中具备可比性，本研究对 U 进行线性投影：

$$\tilde{U} = W_u U + b_u, \tilde{U} \in \mathbb{R}^d \quad (4)$$

其中， W_u 与 b_u 分别为社交特征的线性投影矩阵与偏置项，用于将 U 映射到统一隐藏空间， $\tilde{U}$ 为投影后的社交特征表示， d 为统一隐藏维度。

该投影后的 $\tilde{U}$ 将作为跨域平衡门（DBG）中与内容可信度表示 F_c 进行动态融合输入。

2.5 双阶段门控机制

本研究的特征融合模块采用了门控机制，其核心思想是通过动态调整不同特征在融合过程中的权重，增强有效特征的表示能力，抑制冗余或无关特征的干扰，通过“门”来决定哪些信息应该被保留，哪些信息应该被过滤或抑制。门控机制通过可学习的权重矩阵和激活函数，对输入的多模态特征进行加权求和，从而生成全局特征表示^[23]。本文将融合过程拆解为两级门控：内部融合门（IFG）专注于内容域内部的语义特征与知识推理特征之间的一致性建模与冲突抑制；跨域平衡门（DBG）在获得更稳定的内容可信度表示后，再与用户可信度表示进行样本级动态权衡。该分工式设计使门控权重具有明确语义：IFG 的门控反映“语义—推理证据”的可信配比，DBG 的门控反映“内容—用户”两域在当前样本上的相对可靠性。单一门控往往把域内冲突和域间权衡混在同一个权重里学习，解释性弱且容易过拟合，双阶段实现了门控的分工和约束，从而提升融合的稳定性和可解释性。

此外，Sigmoid 门控机制使得融合操作在逐元素维度上构成凸组合：若门控向量 $g \in (0,1)^d$ ，则融合结果 $h = g \odot x + (1 - g) \odot y$ 的每一维均为对应维度上 x 与 y 的凸组合，可在特征冲突维度上自适应地抑制不可靠来源；同时该融合形式具有幅度上界与有界梯度性质，有助于避免直接相加导致的冲突放大。

2.5.1 内部融合门（Internal Fusion Gate, IFG）

C 为 BERT 输出语义向量，维度为 d_c ； K 为 LLM（GLM）生成的推理特征向量，维度为 d_k 。所有输入先通过可学习线性投影映射到统一表示维度 d ： $\tilde{C} = W_c C + b_c$, $\tilde{K} = W_k K + b_k$ ，其中 $\tilde{C}, \tilde{K} \in \mathbb{R}^d$ ，均为投影后的向量表示。

第一阶段的内部融合门用于融合来自 LLM 的知识增强特征 K 与 BERT 的语义特征 C 。由于两类特征在表达重点与稳定性方面存在显著差异：LLM 推理特征能够捕捉事实一致性与逻辑链，但可能受到幻觉风险影响，而 BERT 特征稳定但缺乏推理深度，因此需要一种可学习机制以动态决定融合比例。

IFG 通过一个 Sigmoid 门控函数生成自适应门控权重：

$$g_c = \sigma(W_g [\tilde{C}; \tilde{K}] + b_g) \in \mathbb{R}^d \quad (5)$$

其中 $[\tilde{C}; \tilde{K}]$ 表示沿通道拼接； $W_g \in \mathbb{R}^{d \times 2d}$, $b_g \in \mathbb{R}^d$ 为 IFG 门控网络参数； σ 为逐元素 Sigmoid。

为了保持原机制的残差结构与稳定性，本研究继续采用多通路残差融合方式：

$$F_c = g_c \odot \tilde{C} + (1 - g_c) \odot \tilde{K} + W_{\text{res}}^{(1)} [\tilde{C}; \tilde{K}] \quad (6)$$

其中 $W_{\text{res}}^{(1)} \in \mathbb{R}^{d \times 2d}$ ，为 IFG 残差支路线性变换参数。由于 $g_c \in (0,1)^d$ ，式（6）前两项在逐维上构成凸组合，即对任意维度 i ， $F_{c,i}^{(mix)} = g_{c,i} \tilde{C}_i + (1 - g_{c,i}) \tilde{K}_i$ ，从而当语义证据与推理证据在某些维度发生冲突（例如方向相反）时，门控可自适应降低不可靠来源在冲突维度上的贡献，避免直接相加造成冲突放大。同时，残差支路用于保留两源的互补信息并提供更稳定的梯度通路，降低门控抑制带来的信息丢失

风险，从而提升融合的鲁棒性与训练稳定性。

该结构兼具选择性与保留性，使模型既能利用 LLM 的推理能力，也能依靠 BERT 的语义稳定性，从而生成更加可靠的内容可信度特征 F_c 。

2.5.2 跨域平衡门 (Domain Balance Gate, DBG)

第二阶段的跨域平衡门用于融合内容可信度特征 F_c 与用户可信度特征 U 。在社交媒体环境中，发布者属性与内容语义往往存在不一致情形，例如高粉丝账号传播错误信息或低等级用户发布真实内容。简单拼接两类特征容易造成特征冲突，因此需要引入门控进行动态平衡。

DBG 在机制设计中延续了与 IFG 一致的可学习门控权重 g_u ，以保持跨阶段融合逻辑的统一性：

$$g_u = \sigma(W_d[F_c; \tilde{U}] + b_d) \in \mathbb{R}^d \quad (7)$$

其中 $W_d \in \mathbb{R}^{d \times 2d}$, $b_d \in \mathbb{R}^d$ ，为 DBG 门控网络参数， g_u 用来刻画当前样本中内容证据相对于用户证据的相对可靠性权重。

随后通过残差融合完成跨域特征协同，输出最终

的特征表示：

$$Z = g_u \odot F_c + (1 - g_u) \odot \tilde{U} + W_{\text{res}}^{(2)}[F_c; \tilde{U}] \quad (8)$$

其中 $W_{\text{res}}^{(2)} \in \mathbb{R}^{d \times 2d}$ ，为 DBG 残差支路线性变换

参数。式 (8) 的门控融合项在逐维上同样形成凸组合，可在内容可信度与发布者可信度不一致的样本中进行自适应权衡：当用户特征可能误导（如高影响力账号传播错误信息）时，模型可学习使对应维度的 g_u 更偏向内容证据；反之当内容特征噪声较大而用户行为更异常时，则可增强用户域贡献。残差项用于保留跨域互补信息并稳定训练，从而避免仅依赖门控加权导致的信息瓶颈。

通过 IFG 与 DBG 的双层结构，LLM-EDGF 能够从内容内部的语义—知识一致性，以及跨域层面的内容—用户可信度之间，分别进行动态融合，使最终得到的融合特征 Z 更具表达力与判别力。（为便于读者查阅，本文涉及的主要数学符号、定义、维度及首次出现位置汇总于表 1）

表 1 数学符号与定义表

Table 1 List of Mathematical Symbols and Definitions

符号	定义	维度	首次出现
U_{user}	用户画像特征向量经处理后的数值	$U_{\text{user}} \in \mathbb{R}^{d_u}$	2.4 式 (1)
U_{prop}	传播行为特征向量经处理后的数值)	$U_{\text{prop}} \in \mathbb{R}^{d_p}$	2.4 式 (2)
d_u	用户画像特征维度	标量	2.4 式 (1)
d_p	传播行为特征维度	标量	2.4 式 (2)
U	原始社交特征拼接向量	$U \in \mathbb{R}^{d_u+d_p}$	2.4 式 (3)
C	原始 BERT 语义向量	$\mathbb{R}^{d_c}$	2.5
K	原始 LLM 推理特征向量	$\mathbb{R}^{d_k}$	2.5
W_u, b_u	社交特征线性投影参数	$W_u \in \mathbb{R}^{d \times (d_u+d_p)}, b_u \in \mathbb{R}^d$	2.4 式 (4)
W_c, b_c	语义特征线性投影参数	$W_c \in \mathbb{R}^{d \times d_c}, b_c \in \mathbb{R}^d$	2.5
W_k, b_k	知识特征线性投影参数	$W_k \in \mathbb{R}^{d \times d_k}, b_k \in \mathbb{R}^d$	2.5
$\tilde{U}$	社交特征投影后向量	$\tilde{U} = W_u U + b_u$	2.4 式 (4)
$\tilde{C}$	语义特征投影后向量	$\tilde{C} = W_c C + b_c$	2.5
$\tilde{K}$	知识特征投影后向量	$\tilde{K} = W_k K + b_k$	2.5
$\odot$	逐元素乘	运算	2.5.1 式 (6)
$\sigma(\cdot)$	Sigmoid 激活函数	函数	2.5.1 式 (5)

g_c	IFG 生成的门控权重	$g_c \in \mathbb{R}^d$	2.5.1 式 (5)
W_g, b_g	IFG 门控网络参数	$W_g \in \mathbb{R}^{d \times 2d}, b_g \in \mathbb{R}^d$	2.5.1
$W_{\text{res}}^{(1)}$	IFG 残差支路线性变换参数	$W_{\text{res}}^{(1)} \in \mathbb{R}^{d \times 2d}$	2.5.1 式 (6)
F_c	IFG 输出的内容可信度表示	$F_c \in \mathbb{R}^d$	2.5.1 式 (6)
g_u	DBG 生成的门控权重	$g_u \in \mathbb{R}^d$	2.5.2 式 (7)
W_d, b_d	DBG 门控网络参数	$W_d \in \mathbb{R}^{d \times 2d}, b_d \in \mathbb{R}^d$	2.5.2 式 (7)
$W_{\text{res}}^{(2)}$	DBG 残差支路线性变换参数	$W_{\text{res}}^{(2)} \in \mathbb{R}^{d \times 2d}$	2.5.2 式 (8)
Z	DBG 输出的最终融合表示	$Z \in \mathbb{R}^d$	2.5.2 式 (8)

2.6 分类模块

在前述双阶段门控融合后，我们得到最终表征向量 Z 。分类模块的核心任务是将该融合表征映射到虚假信息的判别空间，并输出样本为“真实/虚假”的概率。与特征提取与跨域融合模块不同，分类模块不再强调结构归纳偏置，而是承担判别边界学习的角色；在高层语义表征空间中学习一组可分性更强的非线性决策函数。

本文选择 MLP 作为分类器，原因在于：1) 融合后的 Z 已是跨模态/跨域信息的高层摘要，分类阶段更需要通用的非线性映射以拟合复杂边界；2) MLP 具备参数量可控、训练稳定、易于正则化的优点，能在不引入额外结构假设的前提下充分利用 Z 中的判别信号；3) 相较于更复杂的分类，MLP 更不易掩盖前面融合模块的贡献，便于消融分析与可解释性讨论。

具体设计如下：

隐藏层：特征融合后的全局表示首先输入至两个全连接隐藏层，每层均使用 ReLU 激活函数以增强非线性建模能力；

正则化：为防止模型过拟合，在每个隐藏层后加入 Batch Normalization 和 Dropout；

输出层：采用 Sigmoid 激活函数输出 $[0,1]$ 的概率值，表示该文本为虚假信息的可能性。

具体而言：(1) ReLU 提供非线性表达能力，使分类边界能够适应语义相似但立场相反、文本可信但

用户异常等复杂情形；(2) Batch Normalization 对隐层激活进行归一化，有助于稳定不同批次分布下的特征尺度，降低内部协变量偏移，从而提升训练稳定性与泛化；(3) Dropout 通过随机失活抑制特征共适应，减少模型对少数强特征或偶然模式的依赖，提升在跨事件或跨领域场景下的鲁棒性。三者结合使分类头在保持足够拟合能力的同时，具备更好的优化稳定性与泛化能力，从而与前面的特征融合模块形成互补：融合模块负责信息整合与去冲突，分类模块负责稳健决策边界学习。

本文采用二元交叉熵 (Binary Cross-Entropy, BCE) 作为虚假信息检测的目标函数，其直接对应于最大化伯努利分布下的对数似然，适合输出概率 $\hat{y} \in (0,1)$ 的判别模型。为应对数据集中“真实/虚假”样本数量不均衡导致的偏置学习问题，我们在 BCE 中引入类别权重，对少数类错误赋予更高惩罚，提高少数类的召回能力，更贴合实际检测需求。

3 实验设计

3.1 数据集与预处理

3.1.1 数据来源

本研究使用公开数据集与自建微博数据集作为实验数据 (见表 2)，两者在文本风格、语义结构、社交行为模式以及虚假信息类型上呈现明显差异，能够从内容特征与社交特征两个层面全面检验 LLM-EDGF 模型的性能与泛化能力。

表 2 数据集

Table 2 Datasets

数据集	数据规模 (事件)	类别
Politifact	1381	True、False
Gossip	21671	True、False
Twitter15	1490	True、False
Twitter17	2551	True、False
自建微博数据集	新闻数据: 1914	True、False
	用户数据: 18732	
	传播数据: 5742	

公开数据集：本研究选取了 Politifact、Gossip、Twitter15 和 Twitter17，都是国际虚假信息研究领域最具代表性的数据集，结构完整且包含丰富的事实描述与逻辑链条，其真假标签由专业事实核查机构提供，因此具有较高的标注准确性。

Politifact 来源于事实核查平台，样本以新闻为基本单位并带有真实性标注。本文将其作为二分类虚假信息检测任务，标签为 {真实, 虚假}。该数据集不包含传播结构与用户信息，实验仅使用文本内容进行建模与判别，适合评估模型对语义线索与外部知识补全的利用能力。

Gossip 来源于娱乐新闻核查网站，包含真实与虚假的新闻样本。与 Politifact 相同，本文将其设置为二分类任务 {真实, 虚假}，且该数据集不包含传播结构与用户信息，实验仅使用文本内容。该数据集在语言风格与领域分布上与 Politifact 存在差异，可用于验证模型在领域变化下的鲁棒性。

Twitter15 与 Twitter17 为社交媒体谣言数据集，样本通常以事件为组织单位，并提供与事件相关的传播链路信息。原始标注包含 4 类：True、False、Unverified、Non-rumor。为与本文二分类虚假信息检测任务保持一致，我们将其映射为二分类标签：将 True 与 Non-rumor 合并为“真实”，将 False 与 Unverified 合并为“虚假”。其中，Non-rumor 表示经确认的非谣言信息，语义上等价于真实类别；Unverified 表示未经证实的信息，在实际传播中具有较高的不确定性与潜在误导风险，且在许多虚假信息

检测研究中常被作为谣言检测的目标对象之一，因此在本文中与 False 合并处理。上述映射在 Twitter15 和 Twitter17 的训练、验证与测试划分中保持一致。

需要说明的是，DBG 模块用于融合内容特征与样本级社交特征。由于 Politifact、Gossip 不提供传播与用户字段，Twitter15 和 Twitter17 虽提供传播链路但不包含用户画像与推文级互动统计，且公开版本难以在可复现前提下补全相关社交特征，因此本文在公开数据集实验中默认不启用 DBG，仅评估“文本表征 + IFG 融合”路径；在具备社交特征的数据设置下，我们报告完整模型并通过消融实验验证 DBG 的增益。

自建微博数据集：我们构建了一个面向微博平台的虚假信息检测数据集，数据采集时间跨度为 2019 年 1 月至 2025 年 1 月。数据通过微博官网 API 以合规方式获取，采集策略以关键词检索为主，基于百度指数获取候选热词/事件词，并结合热度与相关性对关键词进行筛选与更新，以覆盖不同时间段的热点事件与话题。此外，该数据集包含结构化程度较高的用户属性，如等级、粉丝数、关注数、认证状态等，同时还记录评论数、转发数等传播行为，使其能够真实反映社交媒体高噪声环境下的信息传播机制。样本标签主要来源于微博辟谣以及其他权威事实核查平台和权威媒体辟谣信息：我们依据关键词、事件描述与内容一致性对候选微博与辟谣/核查结论进行对齐，获得初始标签；随后由人工进行复核，重点检查对齐错误、语义歧义与跨事件误匹配等问题，并对存在争议的样本进行再次核查后确定最终标签。最终得到 1914 条样本，其中真实类 1106 条、虚假类 808 条。

3.1.2 数据预处理

为了消除噪声和无关数据对实验的影响，提升模型的性能，我们对自爬微博数据集的原始文本数据进行了以下处理：去除重复数据，保证每条新闻独立唯一；处理乱码与特殊字符；去除停用词（使用哈工大停用词表）；对文本进行拼写错误纠正和格式统一；使用 jieba 完成分词；

数值型字段进行归一化与对数变换，分类变量转

化为布尔类型;

新闻数据按照 8:1:1 比例划分训练集、验证集和测试集, 保证训练过程中的真实新闻和虚假新闻比例一致。

3.2 实验设置

本研究的实验设置围绕 LLM-EDGF 模型的核心思想展开, 即将 LLM 的知识增强能力与 BERT 的高效语义编码以及社交特征的动态权重调节机制进行深度融合。为确保实验的科学性、稳定性与可复现性, 本研究在统一的硬件、软件框架与训练流程下进行全部实验。由于 LLM-EDGF 模型依赖 LLM 生成高质量知识特征, 因此本研究在知识增强阶段选用国产代表性大模型智谱的 GLM-4.5-Flash 作为推理与知识抽取引擎, 兼顾逻辑推理能力、事实校验能力与较高稳定性, 为模型提供结构化知识特征输入。

在实验硬件环境方面, 所有模型的训练与推理均在单张 NVIDIA RTX 3090 GPU (24GB 显存) 上进行, 软件环境使用 PyTorch 2.1 与 Transformers 模块实现深度网络训练。在训练策略上 (见表 3), BERT 模块采用预训练参数进行微调, 选用 AdamW 优化器, 学习率设为 $2e-5$, 批量大小为 16, 训练轮数上限为 8, 并引入线性学习率衰减与早停机制以提升训练稳定性、避免过拟合。

在知识增强阶段, GLM-4.5-Flash 被用于生成包含事实一致性评分、逻辑一致性评分等结构化特征。这些特征通过统一的 Prompt 模板生成, 以最大限度保证特征稳定性并降低大模型的幻觉风险。GLM-4.5-Flash 的输出不参与反向传播, 其参数在整个实验中保持冻结, 仅作为知识生成工具, 以避免端到端训练造成不必要的模型不稳定性或推理偏移。在获得知识特征后, 文本同时输入 BERT 以提取语义向量, 并通过特征对齐与标准化处理进入内部融合门 (IFG)。用户属性向

量与传播特征经过归一化后输入跨域平衡门 (DBG), 以实现内容可信度与发布者可信度的动态调节。

为全面衡量模型性能, 本研究采用 Precision、Recall 与 F1-score 作为主要评价指标, 所有实验均重复 5 次并取平均值, 以降低因随机初始化带来的性能波动。此外, 我们关注社交媒体数据中天然存在的“社交—文本不对齐”扰动情形, 例如高影响力账号发布不实信息而带来的社会信号偏置。为评估 LLM-EDGF 在该类复杂情形下的应对能力, 我们在实验分析中补充了可解释性验证, 并通过门控输出可视化展示模型在冲突场景下对文本与社交特征的自适应取舍, 从而验证其融合决策的稳定性与可解释性。

通过上述实验设置, 本研究能够系统评估 LLM-EDGF 在语义建模、知识增强、社交特征融合与跨域门控机制下的综合能力与稳定性。

表 3 参数设置

Table 3 Parameter Settings

参数类型	值/说明
MAX_LEN	200 (截断文本最大长度)
VOCAB_SIZE	5000 (词汇表大小)
字嵌入维度	50
BERT 输出维度	768 (采用 bert-base-chinese)
用户/传播特征维度	7 维 (经处理后)
批大小	32
最大轮数	8

3.3 提示词设计

本文在主实验中使用的提示词模板为优化后版本 (见图 2), 其特点是: 分步骤指令、严格字段与输出格式、强制证据逐字引用、以及数值范围约束。作为对照, 我们构造一个优化前模板 (见图 3), 该模板为通用自然语言指令, 不强制机器可解析结构, 也不要求输出对应的文本内证据或证据不足的回退规则, 因此更容易产生非结构化、字段缺失或数值越界等不可用输出。




图 3 提示词优化设计

Fig.3 Prompt Optimization Design

我们采用两类指标衡量不同提示词模板的影响：

(1) 有效输出成功率 **Success rate**：当且仅当输出同时满足以下条件时判定为成功： 可被程序解析；必要字段完整（包含两项评分及证据字段）；两项评分数值严格位于 (0,1)；提供与评分对应的输入文本逐字证据用于指明被评估的文本主张。(2) 输出稳定性：对同一样本的多次运行，计算两项评分的标准差（std），std 越小表示输出越稳定。

我们随机抽取 100 条样本，每种提示词模板对每条样本独立运行 10 次，并统计成功率与评分波动。结果如表 4 所示：优化后模板将有效输出成功率从 25% 提升至 100%。在 100% 有效输出前提下，两项评分的 std 分别为：事实一致性 0.0824、逻辑一致性 0.0934，表明结构化提示词显著降低输出波动并提高可复现性。相较之下，优化前的模板输出不满足可解析、字段完整、数值合法、证据存在等约束，导致输出可用性较差且难以进行稳定性统计。

针对“事实一致性”评分，我们将判断参照设定为公开知识，但证据字段严格限定为输入文本中的逐字引用，用于明确模型评估所对应的文本内容，并禁止生成外部链接或虚构引用。与此同时，我们对输出

进行后验校验，并对不合格输出进行过滤或重新生成，从机制上减少幻觉输出。

表 4 不同提示词模板对输出的影响

Table 4 The Impact of Different Prompt Templates on Outputs

提示词模板	Success rate	std	std
		事实一致性	逻辑一致性
优化前	25%	-	-
优化后	100%	0.0824	0.0934

3.4 对比模型

为了验证本文提出的 LLM-EDGF 模型的有效性，本研究选取覆盖浅层统计、深度语义、社交/传播融合以及 LLM 参与的多类对比模型，形成从仅文本到跨域融合、从静态融合到动态融合的分层基线体系。具体模型与设置如下：

(1) TF-IDF+SVM：传统方法，文本特征用 TF-IDF 表示，SVM 作为分类器（线性核，超参数 c 经网格搜索优化）

(2) TextCNN：局部卷积网络，卷积核大小设为 (3,4,5)，每类通道数为 128，使用全局最大池化。

(3) BiLSTM：词嵌入维度 100，双向结构，隐

藏单元数为 64, 输出后连接全连接层并通过 Softmax 进行分类。

(4) BERT: 提取[CLS]表示作为句向量, 接全连接层输出分类结果, 微调采用 bert-base-chinese 模型。

(5) Early Fusion: 将 TF-IDF 文本特征与用户、传播特征拼接输入至分类器。

(6) Late Fusion: 各类特征独立建模后, 分类结果加权融合。

(7) GLM-4.5-Flash Zero-shot: 直接以大语言模型进行零样本判别, 使用固定的指令模板与少量示例, 在不引入外部检索的条件下输出真假标签与置信度, 记录温度与 top-p 等采样参数以控制随机性。

(8) GLM-4.5-Flash 评分 + BERT: 通过统一 Prompt 引导 LLM 生成结构化的知识特征, 对评分进行标准化后, 与 BERT 语义向量进行直接拼接 (不使用门控), 再由 MLP 完成分类, 用于衡量“仅知识增强、缺门控”的效果边界。

(9) GLM-4.5-Flash+BERT+Attention Fusion: 以跨注意力或加权注意力层替代门控机制, 将 LLM 的知识向量作为键/值, BERT 语义向量作为查询, 学习两者的动态匹配权重后与社交特征进行统一融合, 检验注意力型动态融合与门控型动态融合的差异与相对优势。

(10) GCN: 针对 Twitter15 和 Twitter17 包含的事件级传播结构, 我们将每个事件构建为传播图, 节点表示源消息及其转发/回复消息, 边表示传播关系。节点初始特征由文本编码得到, 并通过两层 GCN 进行信息传播与聚合, 最后采用 MLP 完成二分类预测。

(11) GAT: 在与 GCN 相同的传播图构建方式与节点特征设置下, 使用 GAT 以注意力机制对邻居节点信息进行加权聚合, 从而捕捉传播结构中不同节点贡献的差异性, 最终通过图级读出与 MLP 输出真假标签。

(12) BiGCN: 为更充分利用传播树的方向性信息, 我们进一步引入 BiGCN 基线, 分别在自顶向下与自底向上两个方向进行图卷积编码, 并融合两个方向的图表示用于分类。

(注: 上述传播图基线仅适用于具备传播结构信息的 Twitter15 和 Twitter17 数据集; 自建微博数据集当

前仅包含单条消息的传播统计特征与用户画像信息, 缺少可重建转发链路的边与时间戳信息, 无法使用该分类方法。)

4 实验结果与分析

4.1 公开数据集实验:

通过公开数据集, 聚焦仅依赖内容语义的评价场景, 验证 GLM-4.5-Flash 与 IFG 的增益, 评估模型在无用户和传播特征条件下的性能。

根据表 5 公开数据集的结果, LLM-EDGF (无 DBG) 与“GLM-4.5-Flash 评分+BERT”在四个数据集上整体领先于传统方法, 且在社交媒体场景 (Twitter15、Twitter17) 优势更为稳固。尤为关键的是, 即便不引入社交特征与跨域平衡 (去除 DBG), LLM-EDGF 依托 IFG (内部融合门) 对“知识—语义”的选择性整合, 仍能在新闻与社交双场景中取得优异的表现, 表明结构化的推理特征与门控融合在无社交信号时依旧具备强判别力。同时, 相比 GLM-4.5-Flash Zero-shot, GLM-4.5-Flash 评分+BERT 通过将 LLM 推理输出转化为可量化的知识特征并与语义向量进行简单拼接, 可以带来更一致、更稳健的提升, 说明了“LLM 知识结构化 + 学习型融合”优于直接生成式判别, 也进一步佐证了基于 LLM 的推理增强路径整体优于传统纯文本建模范式。

在包含传播结构的 Twitter15 和 Twitter17 上, 我们进一步与传播图建模基线 (GCN、GAT、BiGCN) 进行对比。结果显示, 传播图模型在部分事件上能够利用扩散结构异常获得较强性能, 而本文方法通过 LLM 生成的事实一致性/逻辑连贯性等推理特征补足纯语义模型的推理短板, 并结合双阶段门控在“内容可信度—社交可信度”之间实现动态平衡, 因此在文本存在部分事实编造、叙事链条不连贯等复杂伪造情形下表现更稳定。该结果表明本文方法与传播图建模路线具有互补性: 在传播结构不完整或早期扩散阶段, 内容推理增强与门控融合可提供更及时且可追溯的判别依据。

表 5 公开数据集实验结果

Table 5 Experimental results on public datasets

		Accuracy/%	Precision/%	Recall/%	F1-Score/%
LLM-EDGEF (无 DBG 模块)	Gossip	91.00	92.00	90.50	91.25
	Politifact	91.50	91.80	91.30	91.55
	Twitter15	92.00	92.50	91.80	92.15
	Twitter17	93.00	93.12	92.88	93.00
TF-IDF+SVM	Gossip	81.87	74.58	77.16	75.85
	Politifact	83.33	83.33	83.33	83.33
	Twitter15	80.50	73.20	76.80	74.95
	Twitter17	81.20	74.00	77.50	75.70
TextCNN	Gossip	80.78	80.72	80.75	80.74
	Politifact	79.39	78.71	78.89	78.80
	Twitter15	82.00	81.15	81.90	81.50
	Twitter17	83.10	82.40	82.85	82.60
BiLSTM	Gossip	81.20	81.90	79.17	80.50
	Politifact	81.25	80.80	81.70	81.25
	Twitter15	83.50	83.10	82.85	82.95
	Twitter17	84.70	84.00	83.60	83.80
BERT	Gossip	85.59	86.12	85.69	85.90
	Politifact	86.42	84.19	85.40	84.79
	Twitter15	88.20	87.75	88.20	87.95
	Twitter17	89.50	88.95	89.30	89.10
GLM-4.5-Flash Zero-shot	Gossip	72.80	72.35	73.25	72.80
	Politifact	71.55	71.00	72.10	71.55
	Twitter15	73.60	73.15	74.05	73.60
	Twitter17	74.25	73.80	74.70	74.25
GLM-4.5-Flash 评分 + BERT	Gossip	86.00	86.50	85.90	86.20
	Politifact	87.00	84.80	85.90	85.35
	Twitter15	88.80	88.20	88.70	88.45
	Twitter17	90.00	89.50	89.80	89.65
GCN	Gossip	-	-	-	-
	Politifact	-	-	-	-
	Twitter15	79.34	76.82	74.15	75.46
	Twitter17	80.52	78.25	75.90	77.05
GAT	Gossip	-	-	-	-
	Politifact	-	-	-	-

	Twitter15	81.27	79.04	77.38	78.19
	Twitter17	82.48	80.63	79.21	79.91
BiGCN	Gossip	-	-	-	-
	Politifact	-	-	-	-
	Twitter15	83.65	82.10	81.42	81.76
	Twitter17	84.93	83.75	83.08	83.41

“-” 表示该数据集不包含传播结构信息，传播图模型不适用

4.2 自建微博数据集实验：

通过自建微博数据集验证 LLM 知识增强与双阶段门控机制的效果，并通过消融实验测试模型中各模块的贡献。

根据表 6 的实验结果，可以观察到不同类型模型在虚假信息检测任务中的性能差异。传统文本分类方法 TF-IDF+SVM 和 TextCNN 整体表现较弱，说明浅层特征在面对语义隐含性强的社交媒体文本时表现有限。BiLSTM 与 BERT 在引入上下文建模能力后性能显著提升，F1 分数分别达到了 91.27%和 91.86%。早期与晚期融合方法相较于单一模态进一步提升了性能，验证了社交特征对虚假信息识别的补充价值。

从大语言模型相关实验可以看出，单独依赖

GLM-4.5-Flash 进行 zero-shot推理的效果较为有限，说明直接依赖 LLM 输出仍然难以在复杂场景中获得稳定的判别结果。将 LLM 生成的知识推理与 BERT 表示结合后，性能大幅提升至 92.45%，说明来自 LLM 的外部知识能够有效增强文本语义理解。进一步采用自注意力机制 Attention Fusion 后，模型性能提升至 93.85%，证明结构化融合策略能够更好地利用多模态信息。

与上述模型相比，所提出的 LLM-EDGF 框架在所有评价指标上均取得最优性能。该结果：表明大语言模型生成的推理式知识显著增强了内容特征的推断能力；双阶段门控机制能够有效缓解多源特征冗余与冲突，提高融合质量；改进的轻量化分类模块进一步提升了模型的稳定性与泛化性能。

表 6 自建微博数据集实验结果

Table 6 Experimental results on the self-crawled Weibo dataset

模型	Accuracy/%	Precision/%	Recall/%	F1-Score/%
TF-IDF+SVM	80.37	84.28	80.37	72.99
TextCNN	81.41	84.16	82.67	83.44
BiLSTM	91.28	91.24	91.34	91.27
BERT	92.97	91.35	92.16	91.86
Early Fusion	95.21	92.13	92.46	92.30
Late Fusion	93.22	91.43	87.21	89.27
GLM-4.5-Flash Zero-shot	78.50	76.20	77.80	76.98
GLM-4.5-Flash 评分 + BERT	93.50	92.10	92.80	92.45
GLM-4.5-Flash+ BERT +Attention Fusion	94.80	93.50	94.20	93.85
LLM-EDGF	95.56	98.28	95.96	97.10




图 4 AUC-ROC 曲线（在自建微博数据集上绘制）

Fig.4 AUC-ROC Curve(Plotted on the Self-Constructed Weibo Dataset)

如图 4 所示，我们在自建微博数据集上绘制 AUC-ROC 曲线，AUC 达到 0.9866，表明模型在区分正负样本方面具备极强的判别能力。具体而言，ROC 曲线在低假阳性率区域便迅速上扬并贴近左上角，明显偏离随机分类器的对角基线，说明在不同阈值下能够同时维持较高的灵敏度与较低的误报率。AUC 接近 1 的结果进一步说明模型在虚假信息检测任务中总体表现优秀，适合在高召回或低误报等不同任务之间灵活部署。

4.3 消融实验：测试模型中各模块的有效性

为了验证 LLM-EDGF 模型中各个模块的有效性，本研究设计了一系列消融实验，逐步去除模型的不同模块或特征，生成以下五个变体模型，如表 7 所示：

表 7 消融实验设计

Table 7 Ablation experiment design

模型编号	模型名	目标
A1	w/o GLM-KE	无 LLM 知识增强，衡量知识增强对复杂逻辑伪造与事实冲突识别的增益
A2	w/o BERT	验证深层语义表征的必要性与与 LLM 的互补关系
A3	w/o Social	量化社交维度对鲁棒性的贡献，尤其

		在微博数据集中
A4	w/o IFG	检验 IFG 在处理“知识—语义”内部冲突与选择性保留上的作用
A5	w/o DBG	量化 DBG 对“内容可信度—发布者可信度”动态平衡的作用
A6	w/o Gates	验证双阶段门控结构的总体必要性与增益上限

图 5 消融实验结果表明，去除 GLM 知识增强（w/o GLM-KE）后，F1 显著下降至 0.862，Precision 与 Recall 同步下滑，表明缺失事实一致性与逻辑一致性这类推理特征，会削弱模型对部分真实支撑、逻辑伪造等高仿真样本的辨识力。去除 BERT（w/o BERT）整体指标均显著劣化，印证深层语义表征在承载内容基础语义与上下文依赖上的不可替代性，且与 LLM 推理形成互补。去除社交特征（w/o Social）后 F1 为 0.927，较全模型有一定幅度回落，但仍保持较高水平，说明社交在复杂社交噪声、身份伪装与异常传播下提供了稳健的增益，尤其能平衡“内容可信度—发布者可信度”。对门控结构的消融进一步揭示了双阶段设计的必要性：去除 IFG（w/o IFG）后 F1 为 0.851，说明内部融合门对“知识—语义”的选择性整合有效抑制尺度不匹配与 LLM 噪声；去除 DBG（w/o DBG）F1 为 0.916，相比 w/o IFG 跌幅略小，但仍显著，表明跨域平衡门在动态调节内容与社交权重、缓解两者冲突方面作用关键。完全去除门控（w/o Gates）则使 F1 降至 0.879，印证静态拼接或简单注意力难以处理跨域异构，双阶段门控在稳定性与可解释性上具备系统性优势。




图 5 消融实验结果

Fig.5 Results of Ablation Experiments

4.4 可解释性验证

本文对 LLM-EDGF 的双阶段门控输出进行记录与可视化, 分别展示第一阶段门控 IFG 在特征维度层面的选择行为, 以及第二阶段门控 DBG 在模态层面的再

平衡作用, 从而形成可追溯的融合决策链条。

我们在自建微博测试集中按真实、虚假分层随机抽取 50 条样本 (保持原比例, seed=42), 使用同一最终模型快照进行单次前向推理, BERT 为 bert-base-chinese 微调版, LLM 推理特征为事先缓存结果。




图 6 IFG 热力图

Fig.6 IFG Heatmap

图 6 热力图展示了 IFG 在分层随机抽取的 50 条测试样本 (seed=42), 单次前向推理于同一模型快照: 横轴为样本索引, 纵轴为 g_c 跨样本方差最高的前 100 维, 色值为(0,1)原始权重, 颜色越深表示权重越高。可以观察到: (1) 维度选择性: 热力图中存在若干跨样本持续较高权重的水平条带, 表明 IFG 会稳定强调具有判别力的关键维度; 同时也存在持续低权重维度,

说明门控能够抑制弱贡献或噪声维度。(2) 样本自适应性: 同一维度在不同样本上的权重存在波动, 说明 IFG 并非固定加权, 而是根据输入动态分配维度贡献。由此, 对于任一样本的预测结果, 我们可通过 IFG 权重定位模型在该样本上主要依赖的维度, 从而提高融合过程的可追溯性。




图 7 DBG 文本主导比例

Fig.7 DBG Text-dominated Ratio

在 IFG 完成维度层面的初步筛选后, DBG 进一步在模态层面进行融合再平衡。图 7 给出了 DBG 的文本主导比例在同一批样本与模型配置上 (seed=42) 的可视化结果, 用于表征内容通道在融合中的平均权重。该比例反映在最终决策中, 文本通道相对于其他通道的主导程度: 值越高表示模型更依赖文本通道信号, 值越低表示模型更多依赖非文本通道信号。

从图 7 可见, 不同样本的文本主导比例并不恒定, 而是在一定范围内动态变化, 说明 DBG 能根据样本特征自适应地调整“文本 vs 非文本”的融合权重。该现象为双阶段门控缓解特征冲突的机制提供了更直接的解释路径: 当文本通道与其他通道信号一致时, DBG 倾向于提高文本主导比例以增强有效证据; 当出现冲突或文本证据不足时, DBG 会降低文本主导比例, 从而避免单一通道的偏置放大, 提升融合稳健性与决策透明度。

综上, IFG 提供维度级的可解释选择, DBG 提供模态级的可解释再平衡, 两者共同将融合决策从黑箱转化为可视化、可追溯的权重分配过程。

4.5 计算开销与部署讨论

在评估模型实用性时, 计算开销与资源消耗是关键指标。LLM-EDGF 采用“云端知识增强 + 本地轻量化决策”的架构: 知识增强阶段可通过智谱 GLM-4.5-

Flash 开放平台 API 生成结构化特征, 从而避免在本地部署大规模参数模型, 显著降低本地显存门槛与算力压力。需要指出的是, 端到端在线延迟主要受外部服务的网络状态、并发能力与输入长度等因素影响; 因此在实际部署中可采用批处理与缓存复用以减少平均调用次数并稳定吞吐。

在本地端, 主检测模块由 bert-base-chinese 编码器与轻量级双阶段门控单元构成, 推理开销主要来自 BERT 前向计算以及少量线性投影。在训练阶段, 我们观测到每个 epoch 约耗时 1 分钟, 进行 50 轮训练后取最佳模型, 全部训练过程大约 20 分钟左右即可完成。在推理阶段, 单张 NVIDIA RTX 3090 显卡可以在不到 1 分钟内完成大规模样本的高并发预测, 表明该设计在训练效率和推理速度上都能较好地满足实时检测的需求。

5 结论

本研究围绕社交媒体虚假信息检测中语义理解不足、多源特征耦合复杂与模型泛化性有限等核心问题, 提出了 LLM-EDGF 虚假信息检测框架。该框架通过 BERT 获取文本语义表示, 并引入 GLM 生成的推理式知识向量以实现内容的知识增强, 从而弥补传统文本模型在深层语义推断能力上的不足。同时, 研究构建用户属性与交互行为等社交特征, 结合双阶段门控机

制实现内容特征、知识特征与社交特征的自适应筛选与协同融合,显著缓解了多源信息间的冗余与冲突。实验结果表明,LLM-EDGF 在多个数据集上均显著优于传统文本模型、多模态融合模型及直接依赖大语言模型的 Zero-shot 等推断方法,验证了知识增强与门控融合策略在虚假信息检测中的有效性。总体而言,本研究为多源特征融合与大语言模型辅助推理在虚假信息检测领域的应用提供了新的范式。未来研究,可从提升知识增强的可控性与可靠性、引入传播动态与多模态特征、以及开展跨平台与跨语言实验等方向拓展模型,以构建更具鲁棒性与适用性的虚假信息检测体系。

参考文献:

- [1] MEEL P, VISHWAKARMA D K. Fake news, rumor, information pollution in social media and web: A contemporary survey of state-of-the-arts, challenges and opportunities[J]. Expert Systems with Applications, 2020, 159: 113978.
- [2] 张新生, 王润周, 马玉龙. AIGC 背景下虚假信息治理挑战、机会与策略研究[J]. 情报科学, 2025, 43(5): 78-88, 96.
- ZHANG X S, WANG R Z, MA Y L. Challenges, Opportunities and Strategies of Misinformation Governance at AIGC Background[J]. Information Science, 2025, 43(5): 78-88, 96.
- [3] MA J, GAO W, WONG K F. Detect rumors in microblog posts using propagation structure via kernel learning[C]// Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Stroudsburg: Association for Computational Linguistics, 2017: 850-860.
- [4] 张欣, 孙靖超. 基于大语言模型的虚假信息检测框架综述[J]. 计算机科学与探索, 2025, 19(6): 1414-1436.
- ZHANG X, SUN J C. Review of False Information Detection Frameworks Based on Large Language Models[J]. Journal of Frontiers of Computer Science and Technology, 2025, 19(6): 1414-1436.
- [5] WU L, YANG X, SHI X, et al. Optimizing prompt efficacy in large language models for fake news detection via evolutionary algorithm-based feature selection[J]. Information Sciences, 2025, 720: 122539.
- [6] 原福永, 冯静, 符茜茜. 微博用户的影响力指数模型[J]. 现代图书情报技术, 2012(6): 60-64.
- YUAN F Y, FENG J, FU Q Q. Influence Index Model of Microblog User [J]. Modern Library and Information Technology, 2012(6): 60-64.
- [7] 毛佳昕, 刘奕群, 张敏, 等. 基于用户行为的微博用户社会影响力分析[J]. 计算机学报, 2014, 37(4): 791-800.
- MAO J X, LIU Y Q, ZHANG M, et al. Social Influence Analysis for Micro-Blog User Based on User Behavior [J]. Chinese Journal of Computers, 2014, 37(4): 791-800.
- [8] GUO M, CHEN C, HOU C, et al. FGDGNN: Fine-grained dynamic graph neural network for rumor detection on social media[C]//Findings of the Association for Computational Linguistics: ACL 2025. Stroudsburg: Association for Computational Linguistics, 2025.
- [9] WANG J, SONG D, KALICIAK L. Tensor product of correlated text and visual features: A quantum theory inspired image retrieval framework[C]//Proceedings of the Twenty-Fourth AAAI Conference on Artificial Intelligence. Menlo Park: AAAI Press, 2010: 2363-2368.
- [10] BOULAHIA S Y, AMAMRA A, MADI M R, et al. Early, intermediate and late fusion strategies for robust deep learning-based multimodal action recognition[J]. Machine Vision and Applications, 2021, 32: 121.
- [11] QIAN C X, et al. DynCIM: Dynamic curriculum for imbalanced multimodal learning[R]. arXiv preprint arXiv:2503.06456, 2025.
- [12] DU Y P, et al. Gated attention fusion network for multimodal sentiment classification[J]. Knowledge-Based Systems, 2022, 240: 108107.
- [13] KUMAR A, VEPA J. Gated mechanism for attention based multi modal sentiment analysis[C]//2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2020.
- [14] KOJIMA T, GU S S, REID M, et al. Large language models are zero-shot reasoners[J]. Advances in Neural Information Processing Systems, 2022, 35: 22199-22213.
- [15] HU B Z, SHENG Q, CAO J, et al. Bad actor, good advisor: Exploring the role of large language models in fake news

detection[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2024, 38(20): 22105-22113.

[16] ZHOU X Y, SHARMA A, ZHANG A X, et al. Correcting misinformation on social media with a large language model[R]. arXiv preprint arXiv:2403.11169, 2024.

[17] QI P, YAN Z, HSU W, et al. Sniffer: Multimodal large language model for explainable out-of-context misinformation detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 13052-13062.

[18] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive nlp tasks[C]//Advances in Neural Information Processing Systems. 2020, 33: 9459-9474.

[19] GHOSH B, HASAN S, ARAFAT N A, et al. Logical consistency of large language models in fact-checking[R]. arXiv preprint arXiv:2412.16100, 2024.

[20] WEI J, WANG X Z, SCHUURMANS D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in Neural Information Processing Systems, 2022, 35: 24824-24837.

[21] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Stroudsburg: Association for Computational Linguistics, 2019: 4171-4186.

[22] NASSIRI K, AKHLOUFI M. Transformer models used for text-based question answering systems[J]. Applied Intelligence, 2023, 53(9): 10602-10635.

[23] 孙颖, 侯志强, 杨晨, 等. 基于双模态融合网络的目标检测算法[J]. 光子学报, 2023, 52(1): 203-215.

SUN Y, HOU Z Q, YANG C, et al. Object Detection Algorithm Based on Dual-modal Fusion Network[J]. Acta Photonica Sinica, 2023, 52(1): 203-215.



翁克瑞 (1979-), 男, 博士, 副教授。主要从事大数据分析、系统建模与决策优化的研究, 已发表论文 40 余篇。

WENG Kerui, born in 1979, Ph.D., Associate Professor, Ph.D. supervisor. His research interests include Big Data Analysis, System Modeling, and Decision Optimization, etc.



张薇 (2000-), 女, 硕士研究生。主要从事虚假信息的多模态智能识别与市场影响研究。

ZHANG Wei, born in 2000, M.S. candidate. Her research interests include Multimodal Intelligent Recognition of Disinformation and Market Impact Analysis, etc.



於世为 (1980-), 男, 博士, 教授。主要从事能源 (资源) -环境-经济系统建模与政策的研究工作, 已发表 SCI/SSCI 学术论文 60 余篇。

YU Shiwei, born in 1980, Ph.D., Professor, Ph.D. supervisor (Corresponding Author). His research interests include Energy-Resource-Environment-Economy System Modeling and Policy Analysis, etc.



黄瑞云 (2005-), 男, 本科生。研究方向为深度学习。

HUANG Ruiyun, born in 2005, Undergraduate Student. His research interests include Deep Learning, etc.